# 딥러닝 Tensorflow 기본




# 인공지능(AI) 개요

#### 인공지능(AI) 개념

- " 인공지능(Artificial Intelligence)이란? 인공지능 (Artificial Intelligence)은 인간처럼 사고하고 일하는 지능 기계의 개발을 강조하는 컴퓨터 과학의 한 분야
- "인공지능(AI) 사전적 정의
  "인간이 지닌 지적 능력의 일부 또는 전체를 인공적으로 구현한 것이다."

#### 인공지능(AI) 기존 프로그래밍 비교

- " 기존 프로그래밍은 데이터와 프로그램(규칙)을 입력하면 결과(답)가 출력 된다
- " 인공지능은 데이터와 결과(답)를 입력하면 학습을 통해서 프로그램(규칙)이 얻어진다




" 예) Data [X] : 어떤 과일 한 개, Result [Y] : 바나나

Program : 만일 어떤 과일이 길고 노란씩 을 띠면 바나


나임

#### 인공지능(AI) 기존 프로그래밍 비교

" 기존 프로그래밍(동작 인식 예)



" 인공지능(동작인식 예)



#### 인공지능(AI) 종류

" 인공지능(AI) 분류

[1] 규칙기반 AI: rule-based system,

수동으로 규칙(특징)을 입력하면 기계가 추론,

Prolog, LISP

[2] 학습기반 AI: 머신 러닝(Machine Learning),

데이터를 입력하면 기계가 스스로 새로운

특징을 학습하고 예측

#### 인공지능(AI) 종류

- " 머신 러닝 분류
- [1] 지도학습(Supervised Learning)

답이 주어진 상태에서 학습

- 회귀(Regression)
- 분류(Classification)
- [2] 비지도학습(Unsupervised Learning)

답이 없는 상태에서 학습


- 차원 축소(Dimension Reduction) : PCA(주성분 분석)
- 군집화(Clustering)
- [3] 강화학습(Reinforcement Learning)

답을 모르고 있는 상태에서 답을 알아가는 강한 인공 지능(자아를 갖음, 인간수준), 게임, 알파고(DQN)

#### 머신 러닝과 딥러닝

- " 딥러닝: 머신 러닝 중에서 신경망을 사용하여 학습
- " 좁은 의미의 머신 러닝은 신경망을 사용하지 않는 머신 러닝





# 신경망과 딥러닝 history

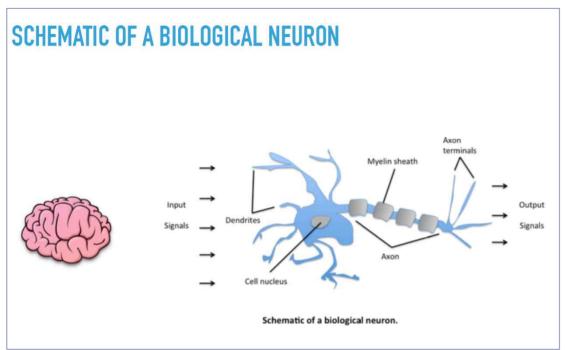
# 퍼셉트론

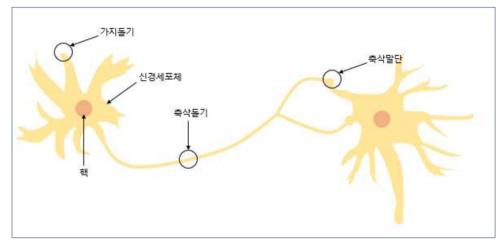
위키백과, 우리 모두의 백과사전.

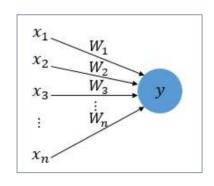
퍼셉트론(perceptron)은 인공신경망의 한 종류로서, 1957년에 코넬 항공 연구소(Cornell Aeronautical Lab)의 프랑크 로젠블라트 (Frank Rosenblatt)에 의해 고안되었다. 이것은 가장 간단한 형태의 피드포워드 (Feedforward) 네트워크 - 선형분류기- 로도 볼 수 있다.

퍼셉트론이 동작하는 방식은 다음과 같다. 각 노드의 가중치와 입력치를 곱한 것을 모두 합한 값이 활성함수에 의해 판단되는데, 그 값이 임계치(보통 0)보다 크면 뉴런이 활성화되고 결과값으로 1을 출력한다. 뉴런이 활성화되지 않으면 결과값으로 -1을 출력한다.

마빈 민스키와 시모어 페퍼트는 저서 "퍼셉트론"에서 단층 퍼셉트론은 XOR 연산이 불가능하지만, 다층 퍼셉트론으로는 XOR 연산이 가능함을 보였다.

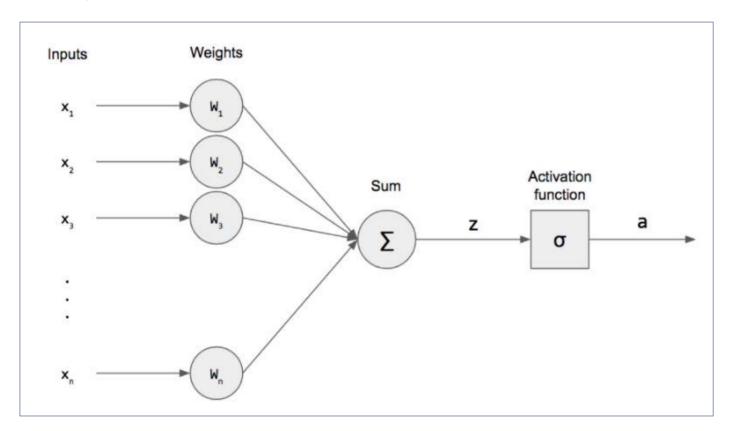






신경 세포 뉴런의 입력 신호와 출력 신호가 퍼셉트론에서 각각 입력 값과 출력 값에 해당된다.

#### Perceptron은 neuron의 구조를 그대로 본따서 만들어졌다



https://roboreport.co.kr/%EC%8B%A0%EA%B2%BD%EB%A7%9D-%EC%9D%B4%EB%A1%A0-%EC%9D%B4%ED%95%B4%ED%95%98%EA%B8%B0-1-perceptron/

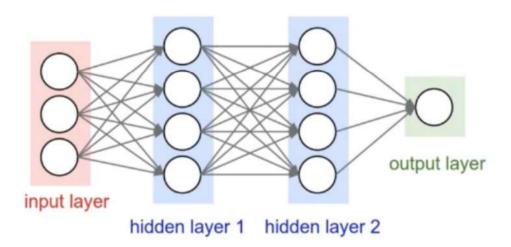
## **XOR PROBLEM**

(Simple) XOR problem: linearly separable?



## **MARVIN MINSKY, 1969**

"No one on earth had found a viable way to train\*"

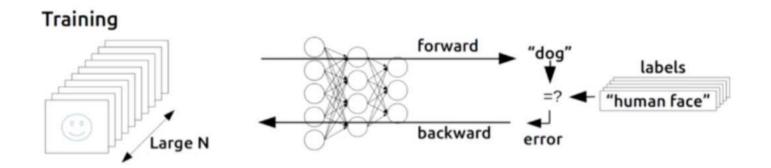


\*Marvin Minsky, 1969

http://cs231n.github.io/convolutional-networks/

## **BACKPROPAGATION**

## Backpropagation (1974, 1982 by Paul Werbos, 1986 by Hinton)



https://devblogs.nvidia.com/parallelforall/inference-next-step-gpu-accelerated-deep-learning/

## **TERMINATOR 2 (1991)**

#### **Terminator 2 (1991)**

JOHN: Can you learn? So you can be... you know. More human. Not such a dork all the time.

**TERMINATOR:** My CPU is a neural-net processor... a learning computer. But **Skynet** presets the switch to "read-only" when we are sent out alone.

We'll learn how to set the neural net

TERMINATOR Basically. (starting the engine, backing out) The Skynet funding bill is passed. The system goes on-line August 4th, 1997. Human decisions are removed from strategic defense. Skynet begins to learn, at a geometric rate. It becomes self-aware at 2:14 a.m. eastern time, August 29. In a panic, they try to pull the plug.

SARAH: And Skynet fights back.

TERMINATOR: Yes. It launches its ICBMs against their targets in Russia.

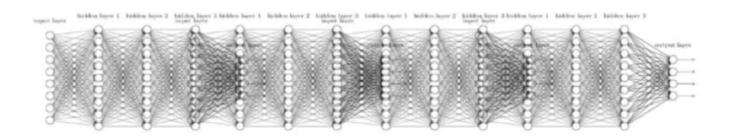
SARAH: Why attack Russia?

**TERMINATOR:** Because **Skynet** knows the Russian counter-strike will remove its enemies here.

http://pages.cs.wisc.edu/~jerryzhu/cs540/handouts/neural.pdf

#### A BIG PROBLEM

- Backpropagation just did not work well for normal neural nets with many layers
- Other rising machine learning algorithms: SVM, RandomForest, etc.
- 1995 "Comparison of Learning Algorithms For Handwritten Digit Recognition" by LeCun et al. found that this new approach worked better



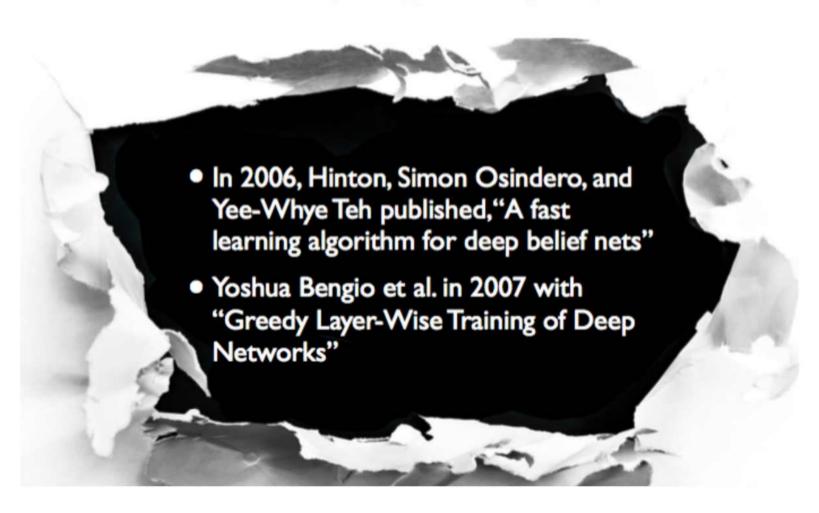
## **CIFAR**

- Canadian Institute for Advanced Research (CIFAR)
- CIFAR encourages basic research without direct application, was what motivated Hinton to move to Canada in 1987, and funded his work afterward.



http://www.andreykurenkov.com/writing/a-brief-history-of-neural-nets-and-deep-learning-part-4/

## BREAKTHROUGH - HINTON(2006), BENGIO(2007)



## BREAKTHROUGH - HINTON(2006), BENGIO(2007)

- Neural networks with many layers really could be trained well, if the weights are initialized in a clever way rather than randomly.
- Deep machine learning methods are more efficient for difficult problems than shallow methods.
- Rebranding to <u>Deep Nets</u>, <u>Deep Learning</u>

# 선형회귀(Linear Regression)

## 1. 회귀분석 (HTTP://MATH7.TISTORY.COM/118 에서 발췌)

- 점들이 퍼져있는 형태에서 패턴을 찾아내고, 이 패턴을 활용해서 무언가를 예측하는 분석.
- 새로운 표본을 뽑았을 때 평균으로 돌아가려는 특징이 있기 때문에 붙은 이름
- ▶ 회귀(回歸 돌 회, 돌아갈 귀)라는 용어는 일반적으로 '돌아간다'는 정도 로만 사용하기 때문에 회귀로부터 '예측'이라는 단어를 떠올리기는 쉽 지 않다.

## 2. LINEAR REGRESSION

- ▶ 2차원 좌표에 분포된 데이터를 1차원 직선 방정식을 통해 표현되지 않 은 데이터를 예측하기 위한 분석 모델.
- ▶ 머신러닝 입문에서는 기본적으로 2차원이나 3차원까지만 정리한다.
- ▶ 여기서는 편의상 1차원 직선으로 정리하고 있다. xy축 좌표계에서 직선을 그렸다고 생각하면 된다.

## 3. HYPOTHESIS

- Linear Regression에서 사용하는 1차원 방정식을 가리키는 용어로, 우리말로는 가설이라고 한다. 수식에서는 h(x) 또는 H(x)로 표현된다.
- ▶ 최저점(minimize cost)이라는 정답을 찾기 위한 가정이기 때문에 가설이라고 부를 수 있다.
- ▶ H(x) = Wx + b ==> x에 대한 1차 방정식

## 4. COST (비용)

- ▶ 앞에서 설명한 Hypothesis 방정식에 대한 비용(cost)으로 방정식의 결과가 크게 나오면 좋지 않다고 얘기하고 루프를 돌 때마다 ₩와 b를 비용이 적게 발생하는 방향으로 수정하게 된다.
- ▶ 미분을 사용해서 스스로 최저 비용을 찾아간다.
- ▶ Gradient Descent Algorithm을 사용해서 최저 비용을 찾는다.

## 5. COST 함수

- ▶ Hypothesis 방정식을 포함하는 계산식
- ▶ 현재의 기울기(W)와 절편(b)에 대해 비용을 계산해 주는 함수
- ▶ W와 b가 변함에 따라 반드시 convex(오목)한 형태로 설계되어야 하는 것이 핵심.
- convex하지 않다면, 경사를 타고 내려갈 수 없기 때문에 최저점 계산 이 불가능해질 수 있다.
- ▶ Linear Regression을 비롯한 머신러닝 전체에서 최소 비용을 검색하기 위한 역할 담당

#### 6. GRADIENT DESCENT ALGORITHM

- ▶ 딥러닝의 핵심 알고리즘
- > 경사타고 내려가기, 경사하강법 등의 여러 용어로 번역되었다.
- ▶ 미분을 사용해서 비용이 작아지는 방향으로 진행하는 알고리즘
- ▶ 생각보다 어렵지 않고 간단한 미분 정도만 이해하면 알고리즘 자체는 너무 단순하다.
- ▶ 텐서플로우에 포함된 Optimizer는 대부분 Gradient Descent Algorithm에서 파생된 방법을 사용하고 있다.

## 회귀(Regression)모델 용어 정리

- [1] 선형 회귀(Linear Regression): 1차 함수, 직선의 방정식
- [2] 가중치(Weight): 입력변수가 출력에 영향을 미치는 정도를 설정, 기울기 값, 회귀 계수
- [3] **편향(Bias)** : 기본 출력 값이 활성화 되는 정도를 설정, y 절편, 회귀 계수
- [4] 비용함수(Cost Function) : 2차 함수, 포물선의 방정식, (예측값 실제값)^2

cost(비용) = 오차 = 에러 = 손실(loss) $cost(W,b) = (H(x) - y)^2$ 

## 회귀(Regression)모델 용어 정리

[5] 예측(가설,Hypothesis) 함수 : predict, H(x) : 예측 값, y값: 답, 결정 값, target, label, x값 : 입력, 피쳐(feature)

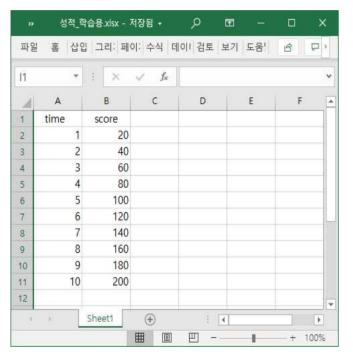
H(X) = W\*X + b

## [6] 경사 하강법(Gradient Descent Algorithm)

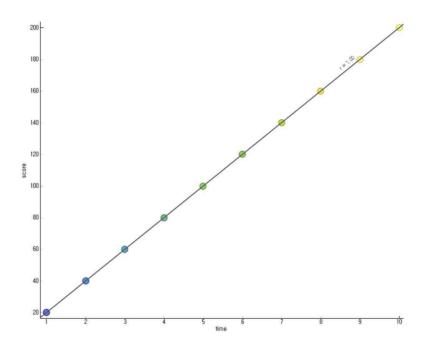
: 비용(cost, loss) 이 가장 작은 Weight(가중치) 값을 구하는 알고리즘

## 회귀용 데이터

#### 학습시간 과 성적과의 관계?

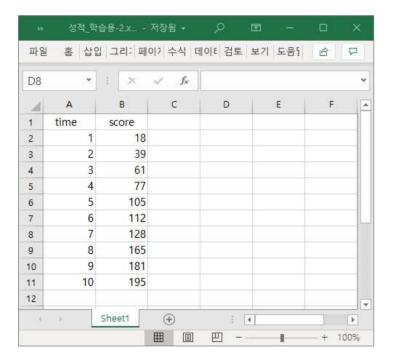


time	score
1	20
2	40
3	60
4	80
5	100
6	120
7	140
8	160
9	180
10	200

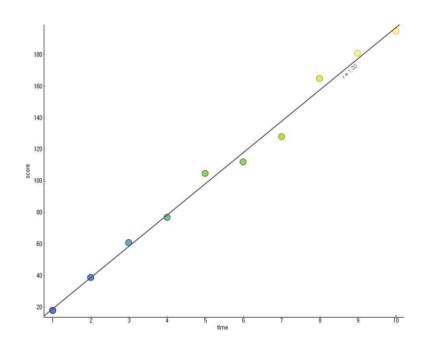


## 실제 오차가 있는 데이터

#### " 오차가 있는 데이터

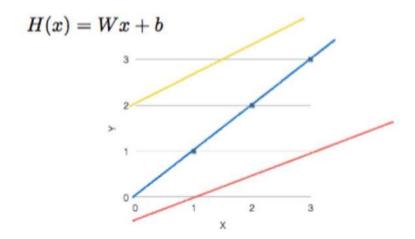


time	score
1	18
2	39
3	61
4	77
5	105
6	112
7	128
8	165
9	181
10	195

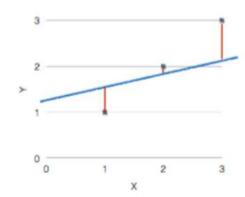


## 좋은 가설?

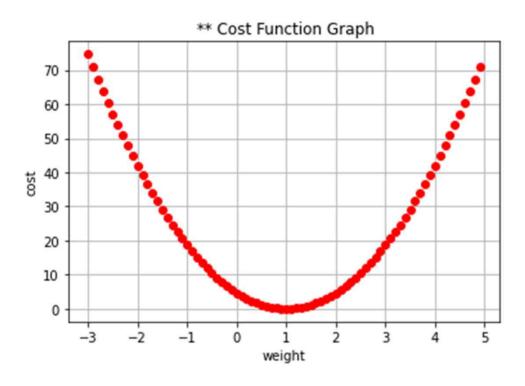
## (Linear) Hypothesis



## Which hypothesis is better?



## 비용함수(Cost Function)



$$cost(W,b) = (H(x) - y)^2$$

## 미분 : 순간 변화량, 기울기, x축으로 1만큼 움직였을 때 y축으로 움직인 거리

- 함수의 미분 공식 정리 :  $f(x) = x^n = ===> f'(x) = n*x^{(n-1)}$ 

• 
$$y = 3$$
 ===>  $y' = 0$ 

• 
$$y = 2*x$$
 ===>  $y' = 2$ 

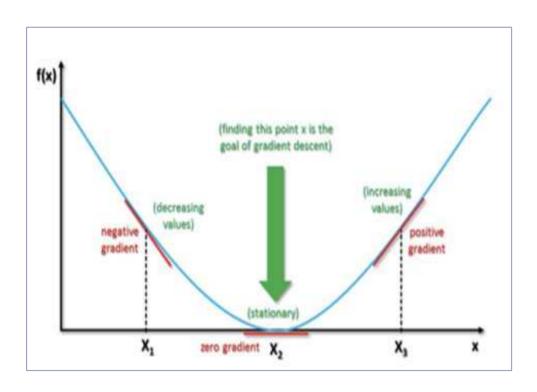
• 
$$y = x^2$$
 ===>  $y' = 2*x$ 

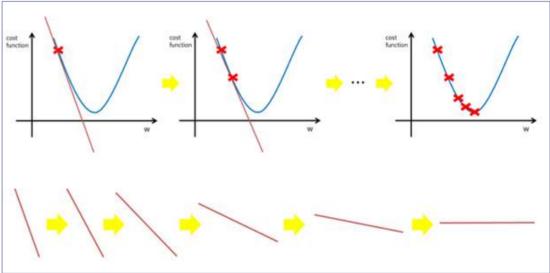
• 
$$y = (x + 1)^2$$
 ===>  $y' = 2*(x + 1)$ 

• 
$$y = x^2 + 2*x + 1 = ==> y' = 2*x + 2$$

• 곱셈 공식 :  $(a + b)^2 = a^2 + 2*a*b + b^2$ 

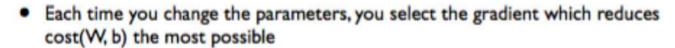
## 경사하강법



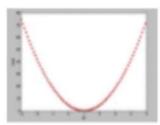


#### **HOW IT WORKS?**

- Start with initial guesses
  - Start at 0,0 (or any other value)
  - Keeping changing W and b a little bit to try and reduce cost(W, b)



- Repeat
- Do so until you converge to a local minimum
- Has an interesting property
  - Where you start can determine which minimum you end up



비용함수의 미분 :  $cost(w) = (w*x - y)^2$  의 미분 , hx = w\*x + 0

cost(w) = 
$$w^2 * x^2 - 2*w*x*y + y^2$$
  
cost'(w) =  $2*w*x^2 - 2*x*y = 2*x*(w*x - y)$   
=  $2*x*(hx - y)$ 

#### FORMAL DEFINITION

$$\begin{split} \cos t(W) &= \frac{1}{m} \sum_{i=1}^m (Wx^{(i)} - y^{(i)})^2 \qquad W := W - \alpha \frac{\partial}{\partial W} \frac{1}{2m} \sum_{i=1}^m (Wx^{(i)} - y^{(i)})^2 \\ \cos t(W) &= \frac{1}{2m} \sum_{i=1}^m (Wx^{(i)} - y^{(i)})^2 \qquad W := W - \alpha \frac{1}{2m} \sum_{i=1}^m 2(Wx^{(i)} - y^{(i)})x^{(i)} \\ W &:= W - \alpha \frac{\partial}{\partial W} \cos t(W) \qquad W := W - \alpha \frac{1}{m} \sum_{i=1}^m (Wx^{(i)} - y^{(i)})x^{(i)} \end{split}$$

#### 텐서플로우

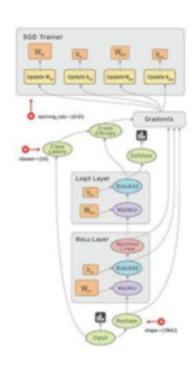
- TensorFlow<sup>™</sup> is an open source software library for numerical computation using data flow graphs.
- Python!



#### 텐서플로우 DATA FLOW GRAPH

## What is a Data Flow Graph?

- Nodes in the graph represent mathematical operations
- Edges represent the multidimensional data arrays (tensors) communicated between them.



## 텐서플로우 속성: RANK

```
t = [[1, 2, 3], [4, 5, 6], [7, 8, 9]]
```

Rank	Math entity	Python example
0	Scalar (magnitude only)	s = 483
1	Vector (magnitude and direction)	v = [1.1, 2.2, 3.3]
2	Matrix (table of numbers)	m = [[1, 2, 3], [4, 5, 6], [7, 8, 9]]
3	3-Tensor (cube of numbers)	t = [[[2], [4], [6]], [[8], [10], [12]], [[14], [16], [18]]]
n	n-Tensor (you get the idea)	

## 텐서플로우 속성 : SHAPE

Rank	Shape	Dimension number	Example
0	0	0-D	A 0-D tensor. A scalar.
1	[D0]	1-D	A 1-D tensor with shape [5].
2	[D0, D1]	2-D	A 2-D tensor with shape [3, 4].
3	[D0, D1, D2]	3-D	A 3-D tensor with shape [1, 4, 3].
n	[D0, D1, Dn-1]	n-D	A tensor with shape [D0, D1, Dn-1].

## 텐서플로우 속성: DTYPE

Data type	Python type	Description
DT_FLOAT	tf.float32	32 bits floating point.
DT_DOUBLE	tf.float64	64 bits floating point.
DT_INT8	tf.int8	8 bits signed integer.
DT_INT16	tf.int16	16 bits signed integer.
DT_INT32	tf.int32	32 bits signed integer.
DT_INT64	tf.int64	64 bits signed integer.

•••

#### 데이터 타입 비교

차원	R	Python	Numpy / Pandas	Tensorflow
0 차원	스칼라(scalar) : 숫자/NA/NULL/문자열/ 진리값/Factor	숫자형(number) 문자열(string)		0-D Tensor
1 차원	벡터(vector) : 한 가지 변수 타입으로 구성	리스트(list) 튜플(tuple)	ndarray / Series	1-D Tensor
2 차원	행렬(matrix) : 한 가지 변수 타입으로 구성		ndarray / x	2-D Tensor
2 차원	데이터 프레임(Data Frame) : 다양한 변수 타입으로 구성		x / DataFrame	
다차원 (2 차원이상)	배열(array) : 2 차원 이상의 행렬		ndarray / x	3-D Tensor / n-D Tensor
다차원	리스트(list) : 서로 다른 데이터 구조 포함	딕셔너리(dictionary)		

#### **MULTI FEATURES**

one-variable one-feature

x (hours)	y (score)
10	90
9	80
3	50
2	60
11	40

#### multi-variable/feature

x1 (hours)	x2 (attendance)	y (score)
10	5	90
9	5	80
3	2	50
2	4	60
11	1	40

#### **MULTI-FEATURES**

# Predicting exam score: regression using three inputs (x1, x2, x3)

#### multi-variable/feature

x <sub>1</sub> (quiz 1)	x <sub>2</sub> (quiz 2)	x <sub>3</sub> (midterm 1)	Y (final)
73	80	75	152
93	88	93	185
89	91	90	180
96	98	100	196
73	66	70	142

#### HYPOTHESIS AND COST FUNCTION

## Hypothesis

$$H(x) = Wx + b$$

$$H(x_1, x_2) = w_1 x_1 + w_2 x_2 + b$$

## Cost function

$$H(x_1, x_2) = w_1 x_1 + w_2 x_2 + b$$

$$cost(W, b) = \frac{1}{m} \sum_{i=1}^{m} (H(x^{(i)}) - y^{(i)})^{2}$$

#### MATRIX AND TRANSPOSE

# Matrix multiplication

## Transpose

$$\begin{bmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \end{bmatrix} \times \begin{bmatrix} 7 & 8 \\ 9 & 10 \\ 11 & 12 \end{bmatrix} = \begin{bmatrix} 58 \\ 9 & 10 \\ 11 & 12 \end{bmatrix} = \begin{bmatrix} 6 & 4 & 24 \\ 1 & -9 & 8 \end{bmatrix}^{\mathsf{T}} = \begin{bmatrix} 6 & 1 \\ 4 & -9 \\ 24 & 8 \end{bmatrix}$$

$$\begin{bmatrix} 6 & 4 & 24 \\ 1 & -9 & 8 \end{bmatrix}^{\mathsf{T}} = \begin{bmatrix} 6 & 1 \\ 4 & -9 \\ 24 & 8 \end{bmatrix}$$

#### **HYPOTHESIS USING MATRIX (1)**

$$w_1x_1 + w_2x_2 + w_3x_3 + ... + w_nx_n$$

$$(x_1 \quad x_2 \quad x_3) \cdot \begin{pmatrix} w_1 \\ w_2 \\ w_3 \end{pmatrix} = (x_1 w_1 + x_2 w_2 + x_3 w_3)$$

$$H(X) = XW$$

## **HYPOTHESIS USING MATRIX (2)**

$$H(x_1, x_2, x_3) = x_1 w_1 + x_2 w_2 + x_3 w_3$$

X <sub>1</sub>	X <sub>2</sub>	X <sub>3</sub>	Y
73	80	75	152
93	88	93	185
89	91	90	180
96	98	100	196
73	66	70	142

Test Scores for General Psychology

$$(x_1 \quad x_2 \quad x_3) \cdot \begin{pmatrix} w_1 \\ w_2 \\ w_3 \end{pmatrix} = (x_1 w_1 + x_2 w_2 + x_3 w_3)$$

$$H(X) = XW$$

#### **HYPOTHESIS USING MATRIX (3)**

X <sub>1</sub>	X <sub>2</sub>	X <sub>3</sub>	Y
73	80	75	152
93	88	93	185
89	91	90	180
96	98	100	196
73	66	70	142

## Hypothesis using matrix

$$w_1x_1 + w_2x_2 + w_3x_3 + ... + w_nx_n$$

$$\begin{pmatrix} x_{11} & x_{12} & x_{13} \\ x_{21} & x_{22} & x_{23} \\ x_{31} & x_{32} & x_{33} \\ x_{41} & x_{42} & x_{43} \\ x_{51} & x_{52} & x_{53} \end{pmatrix} \cdot \begin{pmatrix} w_1 \\ w_2 \\ w_3 \end{pmatrix} = \begin{pmatrix} x_{11}w_1 + x_{12}w_2 + x_{13}w_3 \\ x_{21}w_1 + x_{22}w_2 + x_{23}w_3 \\ x_{31}w_1 + x_{32}w_2 + x_{33}w_3 \\ x_{41}w_1 + x_{42}w_2 + x_{43}w_3 \\ x_{51}w_1 + x_{52}w_2 + x_{53}w_3 \end{pmatrix}$$


$$H(X) = XW$$

#### **HYPOTHESIS USING MATRIX (4)**

$$\begin{pmatrix} x_{11} & x_{12} & x_{13} \\ x_{21} & x_{22} & x_{23} \\ x_{31} & x_{32} & x_{33} \\ x_{41} & x_{42} & x_{43} \\ x_{51} & x_{52} & x_{53} \end{pmatrix} \cdot \begin{pmatrix} w_1 \\ w_2 \\ w_3 \end{pmatrix} = \begin{pmatrix} x_{11}w_1 + x_{12}w_2 + x_{13}w_3 \\ x_{21}w_1 + x_{22}w_2 + x_{23}w_3 \\ x_{31}w_1 + x_{32}w_2 + x_{33}w_3 \\ x_{41}w_1 + x_{42}w_2 + x_{43}w_3 \\ x_{51}w_1 + x_{52}w_2 + x_{53}w_3 \end{pmatrix}$$

[5, 3] [3, 1] [5, 1] 
$$H(X) = XW$$

#### **HYPOTHESIS USING MATRIX (5)**



#### **HYPOTHESIS USING MATRIX (6)**

$$\begin{pmatrix} x_{11} & x_{12} & x_{13} \\ x_{21} & x_{22} & x_{23} \\ x_{31} & x_{32} & x_{33} \\ x_{41} & x_{42} & x_{43} \\ x_{51} & x_{52} & x_{53} \end{pmatrix} \cdot \begin{pmatrix} w_1 \\ w_2 \\ w_3 \end{pmatrix} = \begin{pmatrix} x_{11}w_1 + x_{12}w_2 + x_{13}w_3 \\ x_{21}w_1 + x_{22}w_2 + x_{23}w_3 \\ x_{31}w_1 + x_{32}w_2 + x_{33}w_3 \\ x_{41}w_1 + x_{42}w_2 + x_{43}w_3 \\ x_{51}w_1 + x_{52}w_2 + x_{53}w_3 \end{pmatrix}$$

[n, 3] [3, 1] [n, 1] 
$$H(X) = XW$$

## **HYPOTHESIS USING MATRIX (7)**

$$\begin{vmatrix} x_{11} & x_{12} & x_{13} \\ x_{21} & x_{22} & x_{23} \\ x_{31} & x_{32} & x_{33} \\ x_{41} & x_{42} & x_{43} \\ x_{51} & x_{52} & x_{53} \end{vmatrix} \cdot = \begin{vmatrix} x_{11}w_{11} + x_{12}w_{21} + x_{13}w_{31} & x_{11}w_{12} + x_{12}w_{22} + x_{13}w_{32} \\ x_{21}w_{11} + x_{22}w_{21} + x_{23}w_{31} & x_{21}w_{12} + x_{22}w_{22} + x_{23}w_{32} \\ x_{31}w_{11} + x_{32}w_{21} + x_{33}w_{31} & x_{31}w_{12} + x_{32}w_{22} + x_{33}w_{32} \\ x_{41}w_{11} + x_{42}w_{21} + x_{43}w_{31} & x_{41}w_{12} + x_{42}w_{22} + x_{43}w_{32} \\ x_{51}w_{11} + x_{52}w_{21} + x_{53}w_{31} & x_{51}w_{12} + x_{52}w_{22} + x_{53}w_{32} \end{vmatrix}$$

[n, 3] [?, ?] [n, 2]

$$H(X) = XW$$

### **HYPOTHESIS USING MATRIX (8)**

[n, 3] **[3, 2]** 

[n, 2]

$$H(X) = XW$$

#### **HYPOTHESIS USING MATRIX (9)**

• Lecture (theory):

$$H(x) = Wx + b$$

Implementation (TensorFlow)

$$H(X) = XW$$

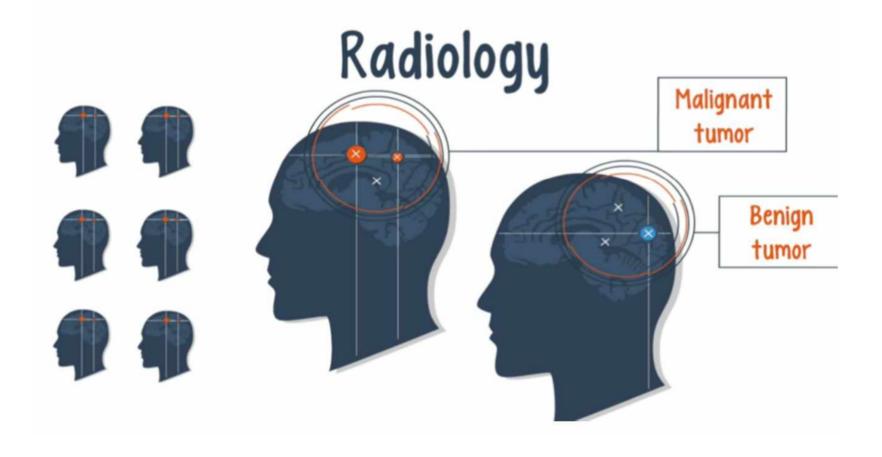
# Logistic Classification

#### **CLASSIFICATION AND ENCODING**

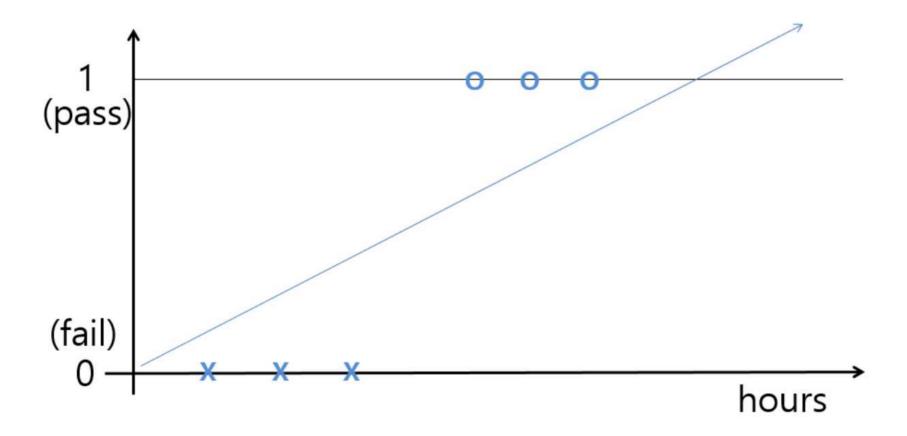
- Spam Detection: Spam or Ham
- Facebook feed: show or hide
- Credit Card Fraudulent Transaction detection: legitimate/fraud

- Spam Detection: Spam (1) or Ham (0)
- Facebook feed: show(1) or hide(0)
- Credit Card Fraudulent Transaction detection: legitimate(0) or fraud (1)

#### **RADIOLOGY**



## **LINEAR REGRESSION?**

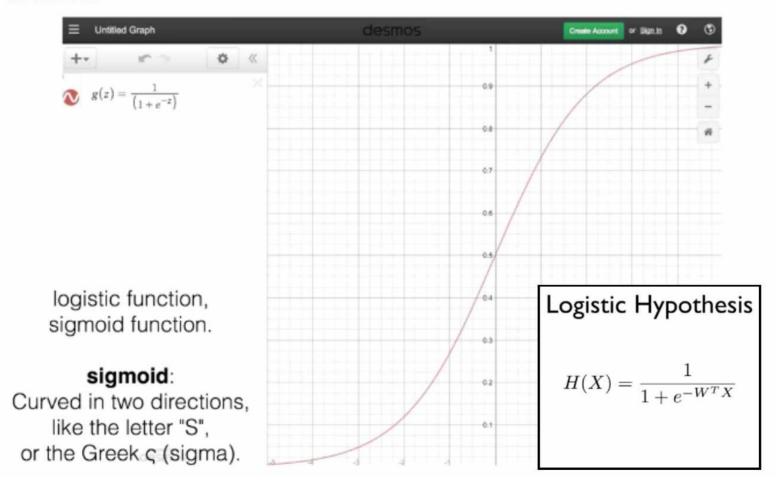


#### **PROBLEMS**

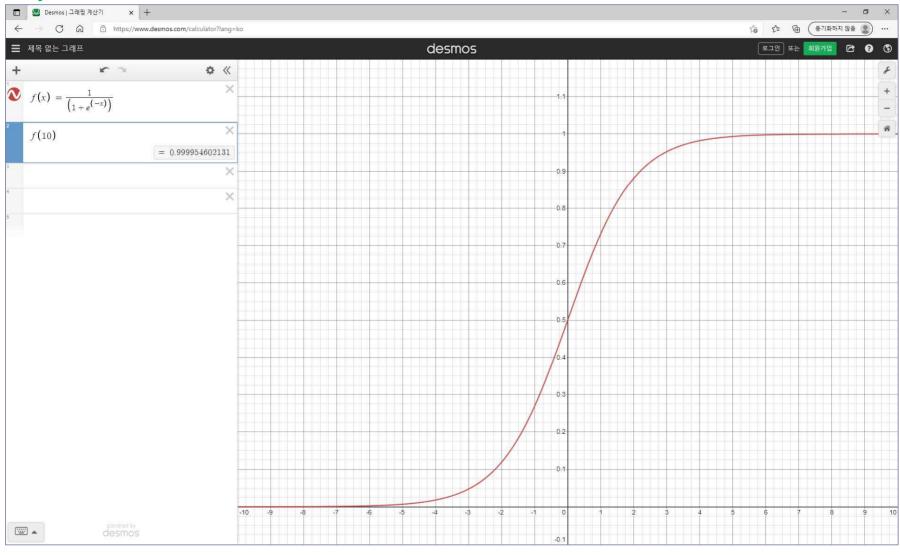
# Linear regression

- We know Y is 0 or I H(x) = Wx + b
- Hypothesis can give values large than I or less than 0

#### SIGMOID



#### https://www.desmos.com/



## 예측함수 : SIGMOID 함수 사용

$$cost(W,b) = \frac{1}{m} \sum_{i=1}^{m} (H(x^{(i)}) - y^{(i)})^2$$
 
$$H(X) = \frac{1}{1 + e^{-W^T X}}$$

$$H(x) = Wx + b$$

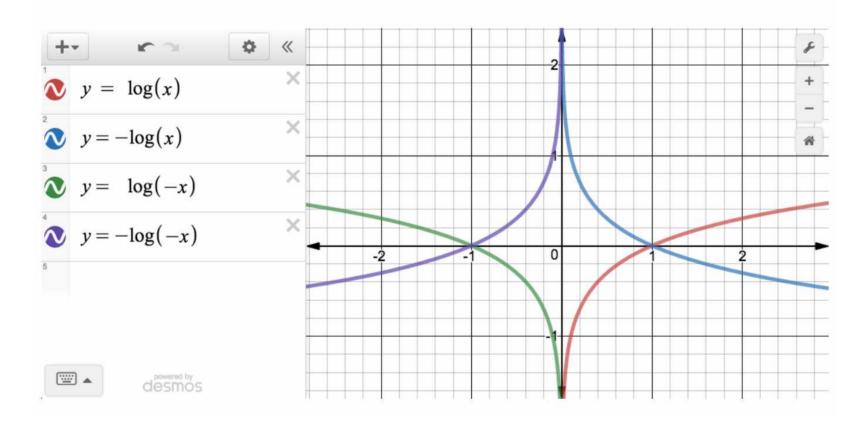
$$H(X) = \frac{1}{1 + e^{-W^T X}}$$

#### **NEW COST FUNCTION FOR LOGISTIC**

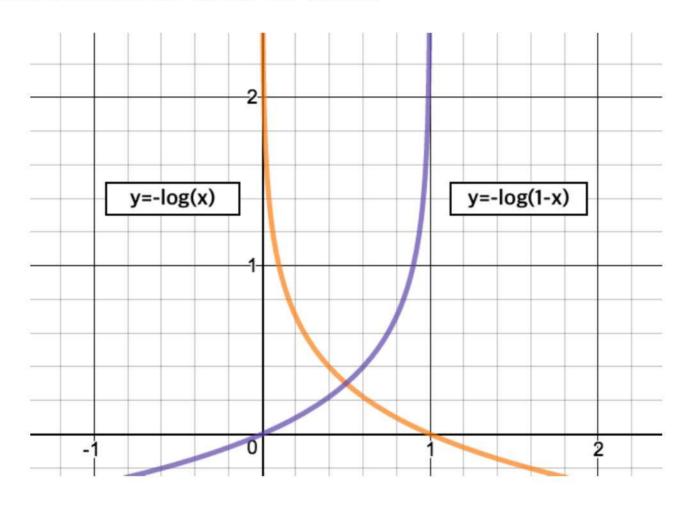
$$cost(W) = \frac{1}{m} \sum c(H(x), y)$$

$$c(H(x), y) = \begin{cases} -log(H(x)) & : y = 1 \\ -log(1 - H(x)) & : y = 0 \end{cases}$$

#### **LOG FUNCTION**



#### **LOG FUNCTIONS WE NEED TO KNOW**



$$log(1) = 0$$

$$log(0) = -\infty$$

$$-log(1) = 0$$

$$-log(0) = +\infty$$

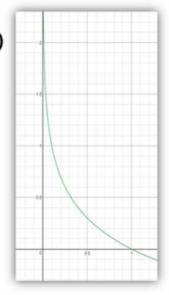
#### **UNDERSTANDING COST FUNCTION**

$$C(H(x),y) = \begin{cases} -log(H(x)) & : y = 1 \\ -log(1-H(x)) & : y = 0 \end{cases}$$

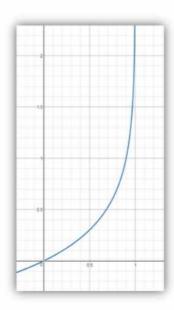
y = 1  

$$H(x) = 1, cost(1) = 0$$
  
 $H(x) = 0, cost(0) = \infty$ 

$$g(z) = -\log(z)$$



$$y = 0$$
  
H(x) = 0, cost(0) = 0  
H(x) = 1, cost(1) =  $\infty$ 



$$g(z) = -\log(1-z)$$

#### **COST FUNCTION**

$$COSt(W) = \frac{1}{m} \sum c(H(x), y)$$

$$C(H(x), y) = \begin{cases} -log(H(x)) & : y = 1 \\ -log(1 - H(x)) & : y = 0 \end{cases}$$

$$C(H(x), y) = -ylog(H(x)) - (1 - y)log(1 - H(x))$$

#### **GRADIENT DESCENT ALGORITHM**

$$cost(W) = -\frac{1}{m} \sum ylog(H(x)) + (1-y)log(1-H(x))$$

$$W := W - \alpha \frac{\partial}{\partial W} cost(W)$$

```
# cost function
cost =-tf.reduce_mean(Y*tf.log(hypothesis) + (1-Y)*tf.log(1-hypothesis))
# Minimize
a = tf.Variable(0.1) # Learning rate, alpha
optimizer = tf.train.GradientDescentOptimizer(a)
train = optimizer.minimize(cost)
```


## **CLASSIFYING DIABETES**


## Classifying diabetes



1	-0.7	-0.894962	-0.23696	0	0	0.213115	0.165829	-0.411765
0	-0.833333	-0.854825	-0.0760059	-0.791962	-0.353535	-0.180328	-0.21608	-0.647059
1	-0.733333	-0.952178	0.052161	0	0	0	0.155779	0.176471
0	0.0666667	-0.931682	-0.0909091	0.283688	-0.0909091	0.147541	0.979899	-0.764706
0	0.1	-0.868488	0	0	0	0.57377	0.256281	-0.0588235
1	-0.7	-0.903501	0.120715	0	0	0.508197	0.105528	-0.529412
0	-0.566667	-0.608027	0.132638	0	0	0.213115	0.688442	0.176471
1	0.2	0.163962	-0.19225	0	0	0.311475	0.396985	0.176471

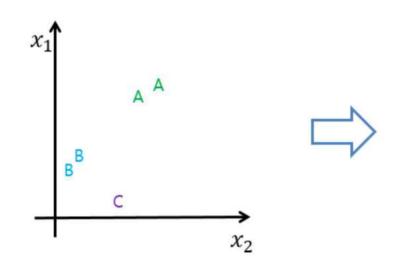
# **DECISION BOUNDARY**

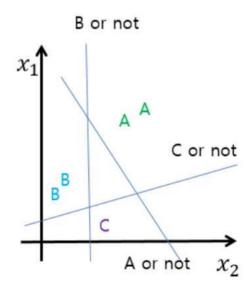


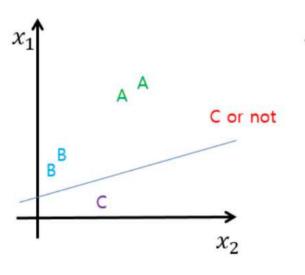


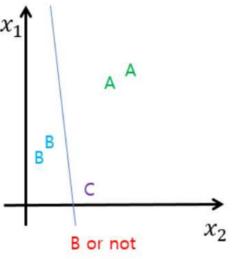
# Multi Classification

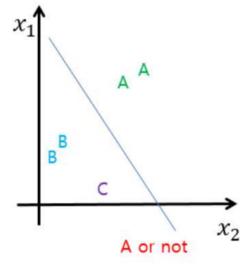
x1 (hours)	x2 (attendance)	y (grade)
10	5	Α
9	5	Α
3	2	В
2	4	В
11	1	С











$$X \to \square \to \hat{Y}$$

$$X \to \square \longrightarrow \widehat{Y}$$

$$X \to \square \to \hat{Y}$$

$$\begin{bmatrix} w_1 & w_2 & w_3 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} w_1 x_1 + w_2 x_2 + w_3 x_3 \end{bmatrix} \qquad X \rightarrow \begin{bmatrix} Z \\ W \end{bmatrix} \rightarrow \hat{Y}$$

$$\begin{bmatrix} w_{A1} & w_{A2} & w_{A3} \\ w_{B1} & w_{B2} & w_{B3} \\ w_{C1} & w_{C2} & w_{C3} \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} =$$

$$X \rightarrow \begin{bmatrix} Z \\ W \\ X \rightarrow \begin{bmatrix} Z \\ Y \end{bmatrix} \rightarrow \hat{Y}$$

$$X \rightarrow \begin{bmatrix} Z \\ W \\ X \rightarrow \begin{bmatrix} Z \\ Y \end{bmatrix} \rightarrow \hat{Y}$$

$$\begin{bmatrix} w_{A1} & w_{A2} & w_{A3} \\ w_{B1} & w_{B2} & w_{B3} \\ w_{C1} & w_{C2} & w_{C3} \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} w_{A1}x_1 + w_{A2}x_2 + w_{A3}x_3 \\ w_{B1}x_1 + w_{B2}x_2 + w_{B3}x_3 \\ w_{C1}x_1 + w_{C2}x_2 + w_{C3}x_3 \end{bmatrix} = \begin{bmatrix} \hat{Y}_A \\ \hat{Y}_B \\ \hat{Y}_C \end{bmatrix}$$

$$X \to \boxed{\qquad} \stackrel{Z}{\longrightarrow} \boxed{\int} \to \widehat{Y}$$

$$X \to \boxed{\qquad} \xrightarrow{Z} \boxed{\qquad} \to \widehat{Y}$$

### WHERE IS SIGMOID?

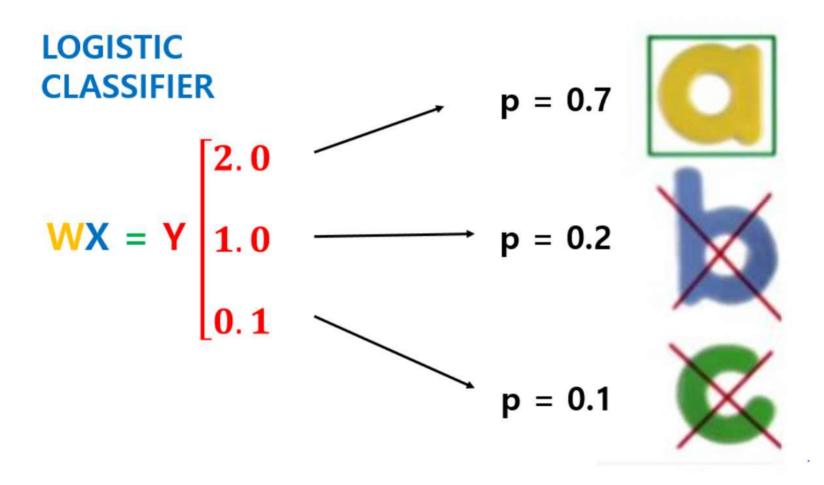
$$\begin{bmatrix} w_{A1} & w_{A2} & w_{A3} \\ w_{B1} & w_{B2} & w_{B3} \\ w_{C1} & w_{C2} & w_{C3} \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} w_{A1}x_1 + w_{A2}x_2 + w_{A3}x_3 \\ w_{B1}x_1 + w_{B2}x_2 + w_{B3}x_3 \\ w_{C1}x_1 + w_{C2}x_2 + w_{C3}x_3 \end{bmatrix} = \begin{bmatrix} \hat{Y}_A \\ \hat{Y}_B \\ \hat{Y}_C \end{bmatrix} \begin{bmatrix} \mathbf{2.0} \\ \mathbf{1.0} \\ \mathbf{0.1} \end{bmatrix}$$







## SIGMOID?



## SOFTMAX

Y 1.0- 
$$S(y_i) = \frac{e^{y_i}}{\sum\limits_{j} e^{y_i}} \longrightarrow 0.2$$
  
0.1-  $0.1$ 

SCORES PROBABILITIES

#### **SOFTMAX**

hypothesis = tf.nn.**softmax**(tf.matmul(X,W)+b)

$$XW = Y \begin{bmatrix} 2.0 & - \\ 1.0 & - \\ 0.1 & - \end{bmatrix} S(y_i) = \frac{e^{y_i}}{\sum\limits_{j} e^{y_i}} \longrightarrow 0.2$$


SCORES ------ PROBABILITIES

## SOFTMAX CROSS ENTROPY WITH LOGITS

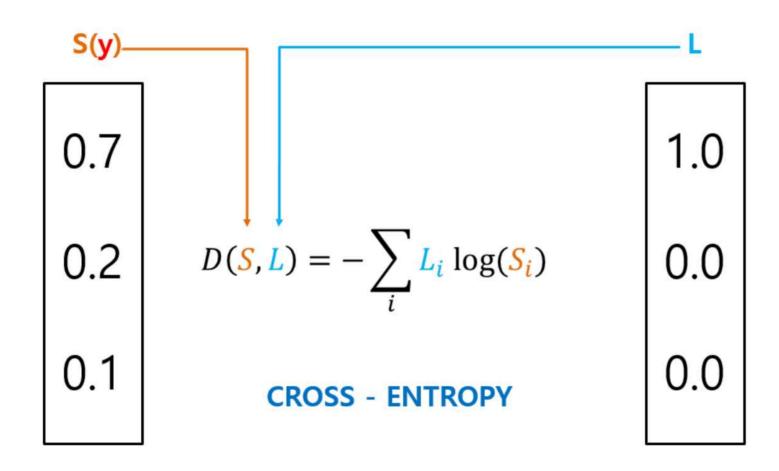
```
logits = tf.matmul(X, W) + b
hypothesis = tf.nn.softmax(logits)
```

```
# Cross entropy cost/loss
cost = tf.reduce_mean(-tf.reduce_sum(Y * tf.log(hypothesis), axis=1))
```


## **ONE-HOT ENCODING**



### **COST FUNCTION**



### **COST FUNCTION**



#### CROSS-ENTROPY COST FUNCTION

$$-\sum_{i} L_{i} \log(S_{i}) \rightarrow -\sum_{i} L_{i} \log(\hat{y}_{i}) \rightarrow \sum_{i} L_{i} * -\log(\hat{y}_{i})$$

$$L = {}_{\mathsf{B}}^{\mathsf{A}} \left[ {}_{1}^{\mathsf{O}} \right] = \mathsf{B}$$

$$\hat{Y} = {}^{\mathsf{A}}_{\mathsf{B}} { \begin{bmatrix} 0 \\ 1 \end{bmatrix}} = \mathsf{B}(0), \qquad { \begin{bmatrix} 0 \\ 1 \end{bmatrix}} * -\log { \begin{bmatrix} 0 \\ 1 \end{bmatrix}} = { \begin{bmatrix} 0 \\ 1 \end{bmatrix}} * { \begin{bmatrix} \infty \\ 0 \end{bmatrix}} = { \begin{bmatrix} 0 \\ 0 \end{bmatrix}} = 0$$


$$\hat{Y} = {}^{\mathsf{A}}_{\mathsf{B}} \begin{bmatrix} 1 \\ 0 \end{bmatrix} = \mathsf{A}(\mathsf{X}), \quad \begin{bmatrix} 0 \\ 1 \end{bmatrix} * -\log \begin{bmatrix} 1 \\ 0 \end{bmatrix} = \begin{bmatrix} 0 \\ 1 \end{bmatrix} * \begin{bmatrix} 0 \\ \infty \end{bmatrix} = \begin{bmatrix} 0 \\ \infty \end{bmatrix} = \infty$$

#### LOGISTIC COST VS. CROSS ENTROPY

$$C(H(x),y) = -y\log(H(x)) - (1-y)\log(1-H(x))$$

$$D(S, L) = -\sum_{i} L_{i} \log(S_{i})$$

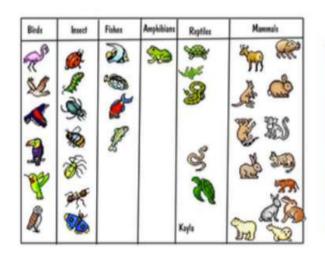
#### **COST FUNCTION: CROSS ENTROPY**



# Cross entropy cost/Loss
cost = tf.reduce\_mean(-tf.reduce\_sum(Y \* tf.log(hypothesis), axis=1))
optimizer = tf.train.GradientDescentOptimizer(learning\_rate=0.1).minimize(cost)

# ANIMAL CLASSIFICATION

## with softmax\_cross\_entropy\_with\_logits



*	0	0	1	0	0	0	2	1	1	0	0	4	1	0	
0	0	1	0	0	1	1	1	1	0	0	1	0	1	0	0
1	0	0	1	0	0	1	1	1	1	0	0	4	0	0	1
1	0	0	1	0	0	1	1	1	1	ð	0	4	2	0	1
1	0	0	1	0	0	0	1.	1	1	0	0	4	1	0	1
1	0	0	1	0	0	0	1	1	1	0	0	4	1	1	1
0	0	1	0	0	1	0	1	1	0	0	1	0	1	1	0
0	0	1	0	0	1	1	1	1	0	0	1	0	1	0	0
1	0	0	1	0	0	0	1	1	1	0	0	4	0	1	0
1	0	0	1	0	0	1	1	1	1	0	0	4	1	0	3
0	1	1	0	1	0	0	0	1	1	0	0	2	1	1	0
0	0	1	0		1	3	1	1	0	0	1	0	1	0	0
0	0	1	0	0	0	1	0	0	0	0	0	0	0	0	0
0	0	1	0	0	1	1	0	0	0	0	0	4	0	0	0
0	0	1	0	0	1	1	0	0	0	0	0	6	0	0	0
0	1	1	0	1	0	1	0	1	1	0	0	2	1	0	0
1	0	0	1	0	0	0	1	1	1	0	0	4	1	0	1

# Keras 기초

# Keras Sequential Layer 의 주요 레이어 정리

- [1] Dense Layer : Fully Connected Layer, layer의 입력과 출력 사이에 있는 모든 뉴런이 서로 연결 되는 Layer
- [2] Flatten Layer : 다차원(4차원)을 단일(*2차원*)으로 축소하여 FC Layer에 전달 한다
- [3] Conv2D Layer : 이미지 특징을 추출하는 Convolution Layer
- [4] MaxPool2D Layer : 중요 데이터(값이 큰 데이터)를 subsampling 하는 Layer
- [5] Dropout Layer : 학습시 신경망의 과적합을 막기위해 일부 뉴런을 제거하는 Layer

#### Sequential 모델을 사용하는 경우

Sequential 모델은 각 레이어에 정확히 하나의 입력 텐서와 하나의 출력 텐서가 있는 일반 레이어 스택에 적합합니다.

개략적으로 다음과 같은 Sequential 모델은

https://www.tensorflow.org/guide/keras/sequential\_model

add() 메서드를 통해 Sequential 모델을 점진적으로 작성할 수도 있습니다.

```
model = keras.Sequential()
model.add(layers.Dense(2, activation="relu"))
model.add(layers.Dense(3, activation="relu"))
model.add(layers.Dense(4))
```

#### Sequential 모델은 다음의 경우에 적합하지 않습니다.

- 모델에 다중 입력 또는 다중 출력이 있습니다
- 레이어에 다중 입력 또는 다중 출력이 있습니다
- 레이어 공유를 해야 합니다
- 비선형 토폴로지를 원합니다(예: 잔류 연결, 다중 분기 모델)

#### 모델이 "빌드"되면, 그 내용을 표시하기 위해 summary() 메서드를 호출할 수 있습니다.

#### model.summary()

Layer (type)	Output Shape	Param #		
dense_7 (Dense)	(1, 2)	10		
dense_8 (Dense)	(1, 3)	9		
dense_9 (Dense)	(1, 4)	16		
Total params: 35				
Trainable params: 35				
Non-trainable params: (	3			

훈련 구성(최적화 프로그램, 손실, 메트릭)을 지정합니다.

```
model.compile(
   optimizer=keras.optimizers.RMSprop(), # Optimizer
   # Loss function to minimize
   loss=keras.losses.SparseCategoricalCrossentropy(),
   # List of metrics to monitor
   metrics=[keras.metrics.SparseCategoricalAccuracy()],
)
```

fit() 를 호출하여 데이터를 "batch\_size" 크기의 "배치"로 분할하고 지정된 수의 "epoch"에 대해 전체 데이터세트를 반복 처리하여 모델을 훈련시킵니다.

```
print("Fit model on training data")
history = model.fit(
    x_train,
    y_train,
    batch_size=64,
    epochs=2,
    # We pass some validation for
    # monitoring validation loss and metrics
    # at the end of each epoch
    validation_data=(x_val, y_val),
)
```

반환되는 "이력" 객체는 훈련 중 손실 값과 메트릭 값에 대한 레코드를 유지합니다.

#### history.history

```
{'loss': [0.3359840214252472, 0.15749482810497284],
  'sparse_categorical_accuracy': [0.903219997882843, 0.9528800249099731],
  'val_loss': [0.17597892880439758, 0.1346321851015091],
  'val_sparse_categorical_accuracy': [0.9488000273704529, 0.9610000252723694]}
```

#### evaluate() 를 통해 테스트 데이터에 대해 모델을 평가합니다.

```
# Evaluate the model on the test data using 'evaluate'

print("Evaluate on test data")

results = model.evaluate(x_test, y_test, batch_size=128)

print("test loss, test acc:", results)

# Generate predictions (probabilities -- the output of the last layer)

# on new data using 'predict'

print("Generate predictions for 3 samples")

predictions = model.predict(x_test[:3])

print("predictions shape:", predictions.shape)
```

#### 저장 및 직렬화

모델 저장 및 직렬화는 Sequential 모델과 같이 함수형 API를 사용하여 빌드된 모델에 대해 같은 방식으로 작동합니다. 함수형 모델을 저장하는 표준 방법은 model.save()를 호출하여 전체 모델을 단일 파일로 저장하는 것입니다. 모델을 빌드한 코드를 더 이상 사용할 수 없는 경우에도 나중에 이파일에서 같은 모델을 다시 작성할 수 있습니다.


저장된 이 파일에는 다음이 포함됩니다.

- 모델 아키텍처
- 모델 중량 값 (훈련 중 학습 된 값)
- 모델 훈련 구성(있는 경우, compile 로 전달)
- 옵티마이저 및 상태(있는 경우, 중단한 곳에서 훈련을 다시 시작)

```
model.save("path_to_my_model")
del model
# Recreate the exact same model purely from the file:
model = keras.models.load_model("path_to_my_model")
```

모델을 그래프로 플롯 할 수도 있습니다.

keras.utils.plot\_model(model, "my\_first\_model.png")



그리고 선택적으로 플롯 된 그래프에 각 레이어의 입력 및 출력 모양을 표시합니다.

 $keras.utils.\underline{plot\_model}(model, \ "my\_first\_model\_with\_shape\_info.png", \ \underline{show\_shapes=True})$ 

